

# Probability Graph 05 Markov Network

Chen Gong

27 November 2019

上一小节中，我们分析了有向图 Bayesian Network，得到了因子分解法， $p(x) = \prod_{i=1}^N p(x_i | x_{pa(i)})$ 。虽然，有向图中可以方便直观的表达条件独立性，但是它也有它的局限性。也就是我们提到的对于 Head to Head 的结构来说，当中间节点被观察到的时候，反而是两端的节点是相关的。这违反了条件独立性的特点，也就是当某些变量被观察到时，其他变量之间是独立的特点，这种情况有点反常，并不太好办。

但是，在无向图中就完全不会出现这样的情况，因为本来就没有方向，而且在无向图中也有类似的 D-Separation 性质。

## 1 Condition Independence in Markov Network

Markov 中的条件独立，大致可以被我们分成三种情况，Global Markov, Local Markov 和 Pair Markov。

### 1.1 Global Markov

假设现在有三个集合  $X_A \perp X_B | X_C$ ，我们想得到  $a \in X_A, b \in X_B$  之间相互独立，这个应该怎么办？我们给出，只有  $a$  和  $b$  的中间节点至少有一个位于  $c$  中，那么我们就可以得到  $a \perp b$ 。

### 1.2 Local Markov

我们以下图的一个 Markov Network 为例，




图 1: Markov Network 示意图

用文字的语言来描述就为  $a \perp \{ \text{全集} - a - \text{邻居} \} | \text{邻居}$ 。那么在这个图中，我们就可以表示为  $a \perp \{e, f\} | \{b, c, d\}$ 。

### 1.3 Pair Markov

成对马尔可夫性质可以被我们描述为： $x_i \perp x_j | x_{-i-j}$  ( $i \neq j$ )。其中， $x_{-i-j}$  为从全集中去掉  $x_i$  和  $x_j$  而留下了的集合。

那么条件独立性就可以提现在，Global, Local 和 Pair 中。其中  $\text{Global} \Leftrightarrow \text{Local} \Leftrightarrow \text{Pair}$ 。也就是这三种条件独立的方法得到的结果是一样的。

## 2 因子分解法

我们想一想在一个无向图中，如何来体现我们想要的条件独立性。这里的引入和之前的不太一样，我们首先需要引入几个概念。**团**：这是一个关于节点的集合，集合中的节点是相互连通的。而最大团，就很好理解了吧，也就是最大的连通子集。我们可以将无向图的分离定义到团上，我们假设  $c_1, c_2, \dots, c_k$  表示为团。那么，我们可以将联合概率定义为：

$$p(x) = \frac{1}{Z} \prod_{i=1}^k \phi(x_{c_i}) \quad (1)$$

其中， $z$  是归一化因子，因为没有归一化因子的话，这不能被称为一个概率分布，因为概率分布首先就要保证和等于 1。那么， $z$  被定义为

$$z = \sum_x \prod_{i=1}^k \phi(x_{c_i}) = \sum_{x_1} \dots \sum_{x_N} \prod_{i=1}^k \phi(x_{c_i}) \quad (2)$$

而这里的因子分解法必定和 Global, Local 和 Pair 都是等价的，但是现在根本就看不出来，那么我们看看后面会怎么说，哈哈！

## 3 Gibbs Distribution 和 Exponential Distribution

这个部分是上面部分的一个加深理解，首先我们需要总结一下。

1. Global Markov:  $X_A \perp X_C | X_B$ 。如果  $A, B, C$  满足  $\text{Sep}(A, C | B)$ ，Sep 代表 D-Separation，那么  $X_A \perp X_C | X_B$ 。

2. Local Markov Network:  $x_i \perp x_{-i-nb(i)} | x_{nb(i)}$ ，其实 nb(i): neighbor of node i。

3. Pair Markov:  $x_i \perp x_j | x_{-i-j}$ 。

$1 \Leftrightarrow 2 \Leftrightarrow 3 \Leftrightarrow$  因子分解 (基于最大团)。这里面实际上是有个 Hammersley-Clifford 定理的，这个定理的证明非常的困难，我们这里就不做过多的阐述 (实际上我也看的有点懵逼，有需求的小伙伴可以查下 Hammersley-Clifford 定理的证明)。

因子分解：

在我们之前的定义中，

$$p(x) = \frac{1}{Z} \prod_{i=1}^k \phi(x_{c_i}) \quad (3)$$

$c_i$ : 最大团;  $x_{c_i}$ : 最大团的随机变量集合;  $\phi(x_{c_i})$ : 势函数, 必须为正。这里的概念都是来自于统计物理学和热力学的过程。这里的势函数还有可以做文章的地方。

因为, 势函数必定为正, 我们可以将势函数表达为  $\phi(x_{c_i}) = \exp\{-E(x_{c_i})\}$ 。其中,  $E(x_{c_i})$  称为 Energy function。实际上用这种形式表达的  $p(x)$ , 为 Gibbs Distribution, 或者又被称之为 Boltzman Distribution。有了  $\phi(x_{c_i})$  的形式, 我们可以进一步推导得:

$$p(x) = \frac{1}{Z} \prod_{i=1}^K \phi(x_{c_i}) = \frac{1}{Z} \prod_{i=1}^K \exp\{-E(x_{c_i})\} = \frac{1}{Z} \exp\left\{-\sum_{i=1}^K E(x_{c_i})\right\} \quad (4)$$

我们再来回顾一下指数族分布, 指数族分布的通用表达形式为:

$$p(x) = h(x) \exp\{\eta^T \phi(x) - A(\eta)\} = h(x) \frac{1}{Z(\eta)} \exp\{\eta^T \phi(x)\} \quad (5)$$

在这里我们把  $\exp\{-A(\eta)\}$ , 直接记为  $Z(\eta)$ 。大家观察就会发现势函数也就是 Gibbs Distribution 就是一个指数族分布。Gibbs 是来自统计物理学, 形式上和指数族分布时一样的。而指数族分布实际上是由最大熵分布得到的, 那么我们可以理解 Gibbs 分布也是有最大熵原理得到的。而马尔可夫随机场 (Markov Random Field) 实际上等价于 Gibbs 分布。至于为什么? 这实际上全部都在 Hammersley-Clifford 定理中, 有兴趣的同学, 请自行查阅。