

Expectation Maximization 01 Algorithm Convergence

Chen Gong

17 December 2019

Expectation Maximization (EM) 算法，中文名字叫做“期望最大”算法。是用来解决具有隐变量的混合模型的高斯分布。在比较简单的情况中，我们可以直接得出我们要求得的参数的解析解，比如：MLE: $p(X|\theta)$ 。我们要求解的结果就是：

$$\theta_{MLE} = \arg \max_{\theta} \log p(X|\theta) \quad (1)$$

其中， $\log p(X|\theta)$ 也被我们称为对数似然函数。一旦，问题变得复杂起来以后，就不是这么简单了，特别是引入了隐变量之后。

1 EM 算法简述

实际上，EM 算法的描述也并不是很难，我们知道，通常我们想求的似然函数为 $p(X|\theta)$ 。引入隐变量之后，原式就变成了：

$$p(X|\theta) = \int p(X, Z|\theta) p(Z|X, \theta) dZ \quad (2)$$

EM 算法是一种迭代的算法，我们的目标是求：

$$\begin{aligned} \theta^{(t+1)} &= \arg \max_{\theta} \int_Z p(X, Z|\theta) p(Z|X, \theta^{(t)}) dZ \\ &= \arg \max_{\theta} \mathbb{E}_{Z \sim p(Z|X, \theta^{(t)})} [\log p(X, Z|\theta)] \end{aligned} \quad (3)$$

也就是找到一个更新的参数 θ ，使得 $\log p(X, Z|\theta)$ 出现的概率更大。

2 EM 算法的收敛性

我们想要证的是当 $\theta^{(t)} \rightarrow \theta^{(t+1)}$ 时，有 $\log p(X|\theta^{(t)}) \leq \log p(X|\theta^{(t+1)})$ 。这样才能说明我们的每次迭代都是有效的。

$$\log p(X|\theta) = \log \frac{p(X, Z|\theta)}{p(Z|X; \theta)} = \log p(X, Z|\theta) - \log p(Z|X; \theta) \quad (4)$$

下一步，则是同时对两边求关于 $p(Z|X, \theta^{(t)})$ 的期望。

左边：

$$\begin{aligned}
\mathbb{E}_{Z \sim p(Z|X, \theta^{(t)})} [\log p(X|\theta)] &= \int_Z p(Z|X, \theta^{(t)}) \log p(X|\theta) dZ \\
&= \log p(X|\theta) \int_Z p(Z|X, \theta^{(t)}) dZ \\
&= \log p(X|\theta) \cdot 1 = \log p(X|\theta)
\end{aligned} \tag{5}$$

右边：

$$\underbrace{\int_Z p(Z|X, \theta^{(t)}) \log p(X, Z|\theta) dZ}_{Q(\theta, \theta^{(t)})} - \underbrace{\int_Z p(Z|X, \theta^{(t)}) \log p(Z|X, \theta) dZ}_{H(\theta, \theta^{(t)})} \tag{6}$$

大家很容易就观察到， $Q(\theta, \theta^{(t)})$ 就是我们要求的 $\theta^{(t+1)} = \arg \max_{\theta} \int_Z p(X, Z|\theta) p(Z|X, \theta^{(t)}) dZ$ 。那么，根据定义，我们可以很显然的得到： $Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta, \theta^{(t)})$ 。当 $\theta = \theta^{(t)}$ 时，等式也是显然成立的，那么我们可以得到：

$$Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta^{(t)}, \theta^{(t)}) \tag{7}$$

这时，大家想一想，我们已经得到了 $Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta^{(t)}, \theta^{(t)})$ 了。如果， $H(\theta^{(t+1)}, \theta^{(t)}) \leq H(\theta^{(t)}, \theta^{(t)})$ 。我们就可以很显然的得出， $\log p(X|\theta^{(t+1)}) \leq \log p(X|\theta^{(t)})$ 了。

证明：

$$\begin{aligned}
H(\theta^{(t+1)}, \theta^{(t)}) - H(\theta^{(t)}, \theta^{(t)}) &= \int_Z p(Z|X, \theta^{(t)}) \log p(Z|X, \theta^{(t+1)}) dZ - \int_Z p(Z|X, \theta^{(t)}) \log p(Z|X, \theta^{(t)}) dZ \\
&= \int_Z p(Z|X, \theta^{(t)}) \log \frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} dZ \\
&= -KL(p(Z|X, \theta^{(t)}) || p(Z|X, \theta^{(t+1)})) \leq 0
\end{aligned} \tag{8}$$

或者，我们也可以使用 Jensen inequality。很显然， \log 函数是一个 concave 函数，那么有 $\mathbb{E}[\log X] \leq \log[\mathbb{E}[X]]$ ，那么：

$$\begin{aligned}
\int_Z p(Z|X, \theta^{(t)}) \log \frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} dZ &= \mathbb{E}_{Z \sim p(Z|X, \theta^{(t)})} \left[\log \frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} \right] \\
&\leq \log \left[\mathbb{E}_{Z \sim p(Z|X, \theta^{(t)})} \left[\frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} \right] \right] \\
&= \log \left[\int_Z p(Z|X, \theta^{(t)}) \left[\frac{p(Z|X, \theta^{(t+1)})}{p(Z|X, \theta^{(t)})} \right] dZ \right] \\
&= \log \int_Z p(Z|X, \theta^{(t+1)}) dZ \\
&= 0
\end{aligned} \tag{9}$$

所以，从两个方面我们都证明了， $\log p(X|\theta^{(t)}) \leq \log p(X|\theta^{(t+1)})$ 。那么，经过每次的迭代，似然函数在不断的增大。这就证明了我们的更新是有效的，也证明了算法是收敛的。