

Boltzmann Machine

Chen Gong

08 April 2020

目录

1	Introduction	1
2	基于极大似然的梯度上升	2
2.1	似然导数求解	2
2.2	似然梯度下降法汇总	3
2.3	小结	3
3	基于 MCMC 的似然梯度下降	4
3.1	MCMC 似然梯度求解总述	4
3.2	条件概率推导	5
3.3	小结	7
4	变分推断法求解	7
4.1	平均场理论求解	7
5	总结	10

玻尔兹曼机 (Boltzmann Machine) 在“受限玻尔兹曼机”那一章就有了简单的描述。在那一章我们就较为详细的分析过了, 由于 Boltzmann machine 中的依赖关系过于复杂, 它的 Learning 和 Inference 问题基本是 intractable。所以, 为了简化而提出了受限玻尔兹曼机 (Restricted Boltzmann Machine)。但是, 为什么又重新谈谈这个似乎不太好的模型呢? 主要原因是 Boltzmann Machine 是深度信念网络 (DBN), 前馈神经网络等网络结构的基础, 大名鼎鼎的变分推断 (Variational Inference) 也是 Hinton 为求解 Boltzmann machine 而提出的。

1 Introduction

Boltzmann machine 节点之间为任意连接, 节点可以分为可观测变量 v 和不可观测变量 h 。每个节点都符合 $\{0, 1\}$ 的伯努利分布。Boltzmann machine 模型的概率图示意图如下所示:




图 1: Boltzmann machine 模型的概率图

其中, $v_{D \times 1} \in \{0, 1\}^D$, $h_{P \times 1} \in \{0, 1\}^P$ 。根据“受限玻尔兹曼”那节的知识, 可以得出, 概率图的联合概率分布为:

$$\begin{cases} P(v, h) = \frac{1}{2} \exp\{-E(v, h)\} \\ E(v, h) = -(v^\top \cdot W \cdot h + \frac{1}{2}v^\top \cdot Lv + \frac{1}{2}h^\top \cdot J \cdot h) \end{cases} \quad (1)$$

其中, $L = [L_{ij}]_{D \times D}$, $J = [J_{ij}]_{P \times P}$, $W = [w_{ij}]_{D \times P}$ 。我相信坚持学到这里的小伙伴们, 对于机器学习的数学推导变换一定有了较好的基础。实际上矩阵的相乘就是用简单的方式来表示连加, 在涉及到求导运算时, 矩阵相乘来代替连加符号, 可以简化推导过程。比如, $v^\top \cdot W \cdot h = \sum_{i=1}^D \sum_{j=1}^P v_i w_{ij} h_j$ 。而 $\frac{1}{2}v^\top \cdot Lv$ 前面为什么要乘上 $1/2$ 呢? 实际上打开就知道了, $v^\top \cdot Lv = \sum_{i=1}^D \sum_{j=1}^D v_i w_{ij} v_j$, 那么很显然 $v_i w_{ij} v_j = v_j w_{ji} v_i$ 。所以, 所有的值都被加了两次, 而我们的目的只要求 v 集合中的任意两个点的乘积, 只需要加一次即可, 当然需要乘上 $\frac{1}{2}$ 。

而这个 $\frac{1}{2}$ 又乘与不乘都没有关系, 因为 $\frac{1}{2}$ 可以藏在 L 里面, 在 Learning 的过程中, 自动的缩小 $\frac{1}{2}$ 就可以了。在此问题中, 要学习的参数集合为 $\theta = \{W, L, J\}$ 。

2 基于极大似然的梯度上升

既然是基于极大似然的梯度上升，显然离不开两个部分，极大似然函数和梯度。总所周知，**极大似然估计的主要思路是，使极大似然函数最大时的参数**。首先明确一下，要求的参数为 $\theta = \{W, L, J\}$ 。样本集合 v ， $|v| = D$ 。那么，似然函数为：

$$\sum_v P(v) = \sum_v \sum_h P(v, h)$$

那么对数似然函数为（实际上 $\frac{1}{D}$ 加不加对于求解没有什么关系，为了严谨起见还是加上）：

$$\frac{1}{D} \sum_v \log P(v)$$

2.1 似然导数求解

那么，下一步就是对对数似然函数求导，即为：

$$\frac{\partial}{\partial \theta} \frac{1}{D} \sum_v \log p(v) = \frac{1}{D} \sum_v \frac{\partial \log p(v)}{\partial \theta} \quad (2)$$

在“直面配分函数”那章的公式 (27)，我们已经详细的推导了 Boltzmann Distribution 的 \log 似然梯度，

$$\frac{1}{D} \frac{\partial}{\partial \theta} \log P(v) = \frac{1}{D} \left(\sum_h \sum_v P(h, v) \frac{\partial}{\partial \theta} E(h, v) - \sum_h P(h|v) \frac{\partial}{\partial \theta} E(h, v) \right) \quad (3)$$

我们主要研究的是对 w 的求导，对其他两个参数矩阵的求导都一样，而且比 w 要更简单一点，这里主要是对 w 求导。小编狠下心来，系统的看了一下矩阵求导，迟早都要学的，建议大家也可以系统的看看，挺有帮助的。那么对 w 参数矩阵的求导如下所示：

$$\begin{aligned} \frac{\partial \log p(v)}{\partial W} &= \sum_v \sum_h p(v, h) \cdot - (vh^\top) - \sum_h p(h|v) \cdot - (vh^\top) \\ &= \sum_i p(h|v) \cdot vh^\top - \sum_{\top} \sum_h p(v, h) \cdot vh^\top \end{aligned} \quad (4)$$

其中， $E(v, h) = -(v^\top W h + \frac{1}{2} v^\top L v + \frac{1}{2} h^\top J h)$ 。注意一下，这里的 v 和 h 矩阵的大小分别为， $D \times 1$ 和 $P \times 1$ 。 $v^\top W h$ 是一个一维的，那么对 $W_{D \times P}$ 求导，得到的也必然是一个 $D \times P$ 的矩阵。那么，很简单可以得到：

$$\frac{1}{D} \sum_v \frac{\partial \log P(v)}{\partial W} = \frac{1}{D} \sum_v \sum_h p(h|v) \cdot vh^\top - \frac{1}{D} \sum_v \sum_v \sum_h P(v, h) \cdot vh^\top \quad (5)$$

看到其中的 $\frac{1}{D} \sum_v \sum_v \sum_h P(v, h) \cdot vh^\top$ ，对 v 和 h 求完和以后，显然 $\sum_v \sum_h P(v, h) \cdot vh^\top$ 是一个常数 C 。所以， $\frac{1}{D} \sum_v \sum_v \sum_h P(v, h) \cdot vh^\top = \frac{1}{D} \sum_v C = \frac{1}{D} D \cdot C = \sum_v \sum_h P(v, h) \cdot vh^\top$ 。所以，公式 (5) 可以改写为：

$$\frac{1}{D} \sum_v \frac{\partial \log P(v)}{\partial W} = \frac{1}{D} \sum_v \sum_h P(h|v) \cdot vh^\top - \sum_v \sum_h P(v, h) \cdot vh^\top \quad (6)$$

而公式 (6) 可以被简写为：

$$\frac{1}{D} \sum_v \frac{\partial \log P(v)}{\partial W} = \mathbb{E}_{P_{\text{data}}} [vh^\top] - \mathbb{E}_{P_{\text{model}}} [vh^\top] \quad (7)$$

其中,

$$\begin{aligned} P_{\text{data}} &= P_{\text{data}}(v) \cdot P_{\text{model}}(h|v) \\ P_{\text{model}} &= P_{\text{model}}(v, h) \end{aligned} \quad (8)$$

为什么这样表达呢? 实际上老师说的很模糊, 我谈谈自己的理解。在 $\sum_v \sum_h P(v, h)$ 中, $P(v, h)$ 是生成模型, 本身就是我们建立的模型, 所以被称为 P_{model} 。而在 $\sum_v \sum_h P(h|v)$ 首先从经验分布 $P(v)$ 从采样得到 v , 然后利用模型分布来求解 $P(h|v)$, 所以 $P_{\text{data}} = P_{\text{data}}(v) \cdot P_{\text{model}}(h|v)$ 。采样出 $P_{\text{model}}(h|v)$ 和 $P_{\text{model}}(v)$ 就可以求解出 $P_{\text{model}}(h, v)$ 了。按照同样的方法可以求得对 $\{L, J\}$ 的导数。

2.2 似然梯度下降法汇总

- Boltzmann Machines 中的节点可以分为可观测变量集合 v 和不可观测变量集合 h 。每个节点属于 0/1 分布, $v_{D \times 1} \in \{0, 1\}^D$, $h_{P \times 1} \in \{0, 1\}^P$ 。
- 参数集合为: $\theta = \{W, L, J\}$ 。参数矩阵的大小为: $L = [L_{ij}]_{D \times D}$, $J = [J_{ij}]_{P \times P}$, $W = [w_{ij}]_{D \times P}$ 。
- Boltzmann Distribution 的模型表示为:

$$\begin{cases} P(v, h) = \frac{1}{2} \exp\{-E(v, h)\} \\ E(v, h) = -\left(v^\top \cdot W \cdot h + \frac{1}{2}v^\top \cdot L v + \frac{1}{2}h^\top \cdot J \cdot h\right) \end{cases} \quad (9)$$

- 求解参数用到极大似然估计, Log-Likelihood Function 为:

$$\frac{1}{D} \sum_v \log P(v) \quad (10)$$

- 通过计算可以得到每个参数矩阵的似然梯度为:

$$\begin{cases} \Delta W = \alpha (\mathbb{E}_{p_{\text{data}}} [vh^\top] - \mathbb{E}_{p_{\text{model}}} [vh^\top]) \\ \Delta L = \alpha (\mathbb{E}_{p_{\text{data}}} [vv^\top] - \mathbb{E}_{p_{\text{model}}} [vv^\top]) \\ \Delta J = \alpha (\mathbb{E}_{p_{\text{data}}} [hh^\top] - \mathbb{E}_{p_{\text{model}}} [hh^\top]) \end{cases} \quad (11)$$

其中:

$$\begin{cases} P_{\text{data}} = P_{\text{data}}(v) \cdot P_{\text{model}}(h|v) \\ P_{\text{model}} = P_{\text{model}}(v, h) \end{cases} \quad (12)$$

2.3 小结

通过上述的求解发现, 梯度的统计量只和 v, h 相关, 只不过分布不一样而已。RBM 也是一种特殊的 Boltzmann Machines, RBM 的求解比较的简单。在“直面配分函数”那一章中可以看到, RBM 在化简完毕后, $P_{\text{data}} = P_{\text{data}}(v)$ 不需要考虑 $P_{\text{model}}(h|v)$, 这样计算起来就非常简单, 梯度在理论上很干净。在前馈神经网络中 Gradient 需要使用链式求导法则, 计算起来非常的复杂。而这里就不一样, 只要解决了后验 $P_{\text{model}}(h|v)$ 就可以了。那么, 下一个重点就是如何从后验 $P_{\text{model}}(h|v)$ 中进行采样。

3 基于 MCMC 的似然梯度下降

3.1 MCMC 似然梯度求解总述

在第二小节中，我们已经讲到了，使用梯度上升法来使 \log 似然函数达到最大，从而求解对应的最优参数。参数更新公式为：

$$\theta^{(t+1)} = \theta^{(t)} + \Delta\theta \quad (13)$$

其中， $\Delta\theta = \{\Delta W, \Delta L, \Delta J\}$ 。以 ΔW 为例， ΔW 是一个矩阵 $\Delta W = [\Delta w_{ij}]$ 。其中，

$$\Delta w_{ij} = \alpha \left[\underbrace{\mathbb{E}_{P_{\text{data}}}[v_i h_j]}_{\text{Postive phase}} - \underbrace{\mathbb{E}_{P_{\text{model}}}[v_i h_j]}_{\text{Negative phase}} \right] \quad (14)$$

这个 Postive 和 Negative phase 的说法，我们在“直面配分函数”那章有详细的描述。那么，**现在的难点就是 $v_i h_j$ 从何而来。**

回忆一下，在 RBM 中， $P(h|v)$ 是可以直接求出来的。

$$P(h|v) = \prod_{l=1}^m P(h_l|v) = \left(\sigma \left(\sum_{j=1}^n w_{lj} v_j + \beta_l \right) \right)^k \left(1 - \sigma \left(\sum_{j=1}^n w_{lj} v_j + \beta_l \right) \right)^{m-k} \quad (15)$$

而 P_{data} 直接从样本中进行采样就可以了，而 $P_{\text{model}}(v, h)$ 为：

$$\begin{aligned} P(h, v) h_i v_j &= \sum_h \sum_v P(v) P(h|v) h_i v_j \\ &= \sum_v P(v) \sum_h P(h|v) h_i v_j \\ &= \frac{1}{Z} \exp \left(\alpha^T v + \sum_{i=1}^m \log(1 + \exp(w_i v + \beta_i)) \right) \sigma \left(\sum_{j=1}^n w_{ij} v_j + \beta_i \right) v_j \end{aligned} \quad (16)$$

这个分布过于复杂，当时采用的是基于对于散度的 Gibbs 采样来解决。而在 Boltzmann Machines 中，Postive phase 和 Negative phase 都是 Intractable。所以，Hinton 提出了用 MCMC 来对 $P(h|v)$ 进行采样。

这里再明确一下逻辑，在求解 ΔW 中，主要是解决三个部分， $P_{\text{data}}(v)$, $P_{\text{model}}(h|v)$, $P_{\text{model}}(v, h)$ ，其中 $P_{\text{model}}(v, h) = P_{\text{model}}(h|v) \cdot P_{\text{model}}(v)$ 。所以，而 $P_{\text{data}}(v)$ 和 $P_{\text{model}}(v)$ 相对比较简单，所以难点在于 $P_{\text{model}}(h|v)$ 的求解。而在 RBM 中 $P_{\text{model}}(h|v)$ 比较容易求解，而 $P_{\text{model}}(v, h)$ 过于复杂，所以要采用 MCMC 来解决。而在 Boltzmann Machines 中，由于关系过于复杂，没有办法分解，甚至最大团分解都没有用，因为最大团就是自己，那么连 $P_{\text{model}}(h|v)$ 都求不出来，那么 Postive phase 和 Negative phase 都是 Intractable。

很幸运的是，通过推导，可以得到：

$$\begin{aligned} P(v_i = 1|h, v_{-i}) &= \sigma \left(\sum_{j=1}^P w_{ij} h_j + \sum_{k=1 \setminus i}^D L_{ik} v_k \right) \\ P(h_j = 1|v, h_{-j}) &= \sigma \left(\sum_{i=1}^D w_{ij} v_i + \sum_{m=1 \setminus j}^P J_{jm} h_m \right) \end{aligned} \quad (17)$$

解释一下，这两个公式是什么意思。公式表达的是，在已知一个节点以外的所有的点的条件下，这个节点的条件概率是可求的。其中 $1 \setminus i$ 表达的意思是 $1 \sim D$ 但不包括 i 的所有节点。

为什么说很幸运呢？因为真实的后验是求不出来的，但是 MCMC 提供了一种一维一维的采样的方法（Gibbs 采样法）。而每一个维的概率分布可以求出来，那么 Gibbs 采样就可以很愉快的被使用了。而且，这个结论同时也可以用在 RBM 中使用，下面我们来举个例子，假设有一个 RBM，如下图所示：




图 2: RBM 概率图模型

由于在已知 v 的情况下， h 中的节点都是相互独立的，所以：

$$P(h|v) = \prod_{j=1}^3 p(h_j|v) \quad (18)$$

同理可得：

$$P(h_j = 1|v) = P(h_j = 1|v, h_{-j}) = \sigma \left(\sum_{i=1}^D w_{ij}v_i + 0 \right) \quad (19)$$

为什么 $\sum_{m=1 \setminus j}^P J_{jm}h_m = 0$ 呢？因为， h 节点内部都是相互独立的，没有边，所有都是 0。实际上在 RBM 那一章，后验是花了较大的功夫去求的。而使用公式 (17) 给出的结论，我们可以较为简单的写出。可以看到，由于 RBM 的特殊性质， h 集合之间相互独立，分解起来非常简单。在 BM 就没有这么好了，虽然每一维可以求出来，由于无法分解，求解起来根本就不可能。

3.2 条件概率推导

在 3.1 节中，给出了两个条件概率分布：

$$\begin{aligned} P(v_i = 1|h, v_{-i}) &= \sigma \left(\sum_{j=1}^P w_{ij}h_j + \sum_{k=1 \setminus i}^D L_{ik}v_k \right) \\ P(h_j = 1|v, h_{-j}) &= \sigma \left(\sum_{i=1}^D w_{ij}v_i + \sum_{m=1 \setminus j}^P J_{jm}h_m \right) \end{aligned} \quad (20)$$

这一节，就来详细的推导一下：

$$\begin{aligned} P(v_i|h, v_{-i}) &= \frac{P(v, h)}{P(h, v_{-i})} = \frac{\frac{1}{Z} \exp\{-\mathbb{E}(v, h)\}}{\sum_{v_i} \frac{1}{Z} \exp\{-\mathbb{E}(v, h)\}} = \frac{\exp\{v^\top W h + \frac{1}{2}v^\top L v + \frac{1}{2}h^\top J h\}}{\sum_{v_i} \exp\{v^\top W h + \frac{1}{2}v^\top L v + \frac{1}{2}h^\top J h\}} \\ &= \frac{\exp\{v^\top W h + \frac{1}{2}v^\top L v\} \cdot \exp\{\frac{1}{2}h^\top J h\}}{\exp\{\frac{1}{2}h^\top J h\} \cdot \sum_{v_i} \exp\{v^\top W h + \frac{1}{2}v^\top L v\}} \end{aligned} \quad (21)$$

由于 $\exp\{\frac{1}{2}h^\top J h\}$ 和 v 没有关系，所以被单独提出来准备约掉。那么有：

$$P(v_i|h, v_{-i}) = \frac{\exp\{v^\top W h + \frac{1}{2}v^\top L v\}}{\sum_{v_i} \exp\{v^\top W h + \frac{1}{2}v^\top L v\}} \quad (22)$$

令 $v_i = 1$ 和分母部分没有关系，因为 \sum_{v_i} 之后，是和 v_i 无关的部分了。所以，

$$P(v_i = 1|h, v_{-i}) = \frac{\exp\{v^\top Wh + \frac{1}{2}v^\top Lv\}|_{v_i=1}}{\exp\{v^\top Wh + \frac{1}{2}v^\top Lv\}|_{v_i=1} + \exp\{v^\top Wh + \frac{1}{2}v^\top Lv\}|_{v_i=0}} \quad (23)$$

为了简化公式，我们将公式简写为：

$$P(v_i = 1|h, v_{-i}) = \frac{\Delta|_{v_i=1}}{\Delta|_{v_i=0} + \Delta|_{v_i=1}} \quad (24)$$

下一步很自然的想到，将包含 v_i 的项，从公式中分离，然后赋予相应的值。

$$\begin{aligned} \Delta v_i &= \exp\left\{v^\top wh + \frac{1}{2}v^\top Lv\right\} = \exp\left\{\sum_{\hat{i}=1}^D \sum_{j=1}^P v_{\hat{i}} w_{\hat{i}j} h_j + \frac{1}{2} \sum_{\hat{i}=1}^D \sum_{k=1}^D v_{\hat{i}} L_{\hat{i}k} v_k\right\} \\ &= \exp\left\{\sum_{\hat{i}=1 \setminus i}^D \sum_{j=1}^P v_{\hat{i}} w_{\hat{i}j} h_j + \sum_{j=1}^P v_i w_{ij} h_j \right. \\ &\quad \left. + \frac{1}{2} \left(\sum_{\hat{i}=1 \setminus i}^D \sum_{k=1}^D v_{\hat{i}} L_{\hat{i}k} v_k + v_i L_{ii} v_i + \sum_{\hat{i}=1 \setminus i}^D v_{\hat{i}} L_{\hat{i}i} v_i + \sum_{\hat{k}=1 \setminus i}^D v_i L_{ik} v_k \right) \right\} \end{aligned} \quad (25)$$

又因为 $L_{ii} = 0$ ，且 L 矩阵是对称的，所以 $\sum_{\hat{i}=1 \setminus i}^D v_{\hat{i}} L_{\hat{i}i} v_i = \sum_{\hat{k}=1 \setminus i}^D v_i L_{ik} v_k$ 。所以，

$$\begin{aligned} \Delta v_i &= \exp\left\{\sum_{\hat{i}=1 \setminus i}^D \sum_{j=1}^P v_{\hat{i}} w_{\hat{i}j} h_j + \sum_{j=1}^P v_i w_{ij} h_j + \frac{1}{2} \left(\sum_{\hat{i}=1 \setminus i}^D \sum_{k=1}^D v_{\hat{i}} L_{\hat{i}k} v_k + 2 \sum_{\hat{k}=1 \setminus i}^D v_i L_{ik} v_k \right) \right\} \\ &= \exp\left\{\sum_{\hat{i}=1 \setminus i}^D \sum_{j=1}^P v_{\hat{i}} w_{\hat{i}j} h_j + \sum_{j=1}^P v_i w_{ij} h_j + \frac{1}{2} \sum_{\hat{i}=1 \setminus i}^D \sum_{k=1}^D v_{\hat{i}} L_{\hat{i}k} v_k + \sum_{\hat{k}=1 \setminus i}^D v_i L_{ik} v_k \right\} \end{aligned} \quad (26)$$

其中， $\frac{1}{2} \sum_{\hat{i}=1}^D \sum_{k=1}^D v_{\hat{i}} L_{\hat{i}k} v_k$ 是按这样的方式进行分解：

$$\begin{cases} \hat{i} \neq i, k \neq i & (D-1)(D-1) \\ \hat{i} = i, k = i & 1 \\ \hat{i} = i, k \neq i & (D-1) \\ \hat{i} \neq i, k = i & (D-1) \end{cases} \quad (27)$$

而 $(D-1)(D-1) + (D-1) + (D-1) + 1 = D^2$ 。

那么，使用公式 (26) 的推导结果，可以得到：

$$\Delta v_{i=0} = \exp\left\{\sum_{\hat{i}=1 \setminus i}^D \sum_{j=1}^P v_{\hat{i}} w_{\hat{i}j} h_j + \frac{1}{2} \sum_{\hat{i}=1 \setminus i}^D \sum_{k=1}^D v_{\hat{i}} L_{\hat{i}k} v_k\right\} = \exp\{A + B\} \quad (28)$$

其中， $A = \sum_{\hat{i}=1 \setminus i}^D \sum_{j=1}^P v_{\hat{i}} w_{\hat{i}j} h_j$ ， $B = \frac{1}{2} \sum_{\hat{i}=1 \setminus i}^D \sum_{k=1}^D v_{\hat{i}} L_{\hat{i}k} v_k$ 。同理可得：

$$\Delta v_{i=1} = \exp\left\{A + B + \sum_{j=1}^P w_{ij} h_j + \sum_{\hat{k}=1 \setminus i}^D L_{ik} v_k\right\} \quad (29)$$

所以，将公式 (28) 和 (29) 的结果代入到公式 (24) 中可得：

$$\begin{aligned}
P(v_i = 1|h, v_{-i}) &= \frac{\Delta|_{v_i=1}}{\Delta|_{v_i=0} + \Delta|_{v_i=1}} \\
&= \frac{\exp\left\{A + B + \sum_{j=1}^P w_{ij}h_j + \sum_{\hat{k}=1 \setminus i}^D L_{ik}v_k\right\}}{\exp\left\{A + B + \sum_{j=1}^P w_{ij}h_j + \sum_{\hat{k}=1 \setminus i}^D L_{ik}v_k\right\} + \exp\{A + B\}} \\
&= \frac{\exp\left\{\sum_{j=1}^P w_{ij}h_j + \sum_{\hat{k}=1 \setminus i}^D L_{ik}v_k\right\}}{\exp\left\{\sum_{j=1}^P w_{ij}h_j + \sum_{\hat{k}=1 \setminus i}^D L_{ik}v_k\right\} + 1} \\
&= \sigma\left(\sum_{j=1}^P w_{ij}h_j + \sum_{\hat{k}=1 \setminus i}^D L_{ik}v_k\right)
\end{aligned} \tag{30}$$

而 $P(h_j = 1|v, h_{-j}) = \sigma\left(\sum_{i=1}^D w_{ij}v_i + \sum_{m=1 \setminus j}^P J_{jm}h_m\right)$ 的计算采用的也是同样的思路。

3.3 小结

本小节主要讲述了基于 MCMC 的似然梯度下降法，不同于 RBM，在 BM 中后验分布 $P(h|v)$ 过于复杂，所以采用 MCMC 采样的思路来求解。幸运的是， $P(h|v)$ 的条件概率是可求的，所以，可以用 Gibbs 采样。然后，给出了条件概率的详细推导。

4 变分推断法求解

我们采用的是梯度上升法，那么在每一次求解梯度的过程中，都要采样得到 vh^\top 。在采样的过程中，主要是对 $P_{\text{model}}(h|v)$ 进行采样，使用 MCMC 采样的劣势大家都很清楚，无法求解大规模问题。如何求解大规模问题一直是难点，直到 90 年代初，Hinton 提出了变分推断法 (Variational Inference) 来求 $P_{\text{model}}(h|v)$ 。

4.1 平均场理论求解

这部分的基础思想，在“近似推断”那一章有非常详细的描述。大体上说就是通过优化下界 ELBO，来达到求解的效果，有兴趣的同学请回顾“近似推断”。公式近似推断中的公式 (5) 可得：

$$\begin{aligned}
\mathcal{L} = \text{ELBO} &= \log P_\theta(v) - \text{KL}(Q_\phi||P_\theta) \\
&= \sum_h Q_\phi(h|v) \log P_\theta(v, h) + H(Q_\phi)
\end{aligned} \tag{31}$$

根据平均场理论（假设分布可以分解成几个部分之积），假定 $Q_\phi(h|v) = \prod_{j=1}^P Q_\phi(h_j|v)$ ，令 $Q_\phi(h_j = 1|v) = \phi_j$ ， ϕ 就可以认为是 $\{\}$ 。那么推导过程如下所示：

$$\begin{aligned}
\hat{\phi}_j &= \arg \max_{\phi_j} \mathcal{L} = \arg \max_{\phi_j} \sum_h Q_\phi(h|v) \log P_\theta(v, h) + H(Q_\phi) \\
&= \arg \max_{\phi_j} \sum_h Q_\phi(h|v) \left[-\log Z + v^\top W h + \frac{1}{2} v^\top L v + \frac{1}{2} h^\top J h \right] + H(Q_\phi)
\end{aligned} \tag{32}$$

$$= \arg \max_{\phi_j} \sum_h Q_\phi(h|v) \left[-\log Z + \frac{1}{2} v^\top L v \right] + \arg \max_{\phi_j} \sum_h Q_\phi(h|v) \left[v^\top W h + \frac{1}{2} h^\top J h \right] + H(Q_\phi) \quad (33)$$

其中, ϕ_j 是和 h 相关的参数, $[-\log Z + \frac{1}{2} v^\top L v +]$ 与 ϕ 没有关系, 那么 $\sum_h Q_\phi(h|v) [-\log Z + \frac{1}{2} v^\top L v +]$ 可以写成 $[-\log Z + \frac{1}{2} v^\top L v] \sum_h Q_\phi(h|v)$ 。很显然, $\sum_h Q_\phi(h|v) = 1$, 所以, $\arg \max_{\phi_j} \sum_h Q_\phi(h|v) [-\log Z + \frac{1}{2} v^\top L v]$ 和 ϕ 没有关系, 可以直接约掉。化简之后,

$$\begin{aligned} \hat{\phi}_j &= \arg \max_{\phi_j} \sum_h Q_\phi(h|v) \left[v^\top W h + \frac{1}{2} h^\top J h \right] + H(Q_\phi) \\ &= \arg \max_{\phi_j} \sum_h Q_\phi(h|v) v^\top W h + \frac{1}{2} \sum_h Q_\phi(h|v) h^\top J h + H(Q_\phi) \\ &= \arg \max_{\phi_j} \textcircled{1} + \textcircled{2} + \textcircled{3} \end{aligned} \quad (34)$$

那么, 下一步工作就是将 h_j 分离出来。

$$\begin{aligned} \textcircled{1} &= \sum_h Q_\phi(h|v) \cdot \sum_{i=1}^D \sum_{j=1}^P v_i w_{ij} h_j \\ &= \sum_h \prod_{j=1}^P Q_\phi(h_j|v) \cdot \sum_{i=1}^D \sum_{j=1}^P v_i w_{ij} h_j \end{aligned} \quad (35)$$

$\sum_{i=1}^D \sum_{j=1}^P v_i w_{ij} h_j$ 中一共有 $D \times P$ 项, 这里太复杂了, 我们先挑一项来分析一下。

$$\begin{aligned} \textcircled{1} &= \sum_h \prod_{j=1}^P Q_\phi(h_j|v) \cdot v_1 w_{12} h_2 \\ &= \sum_{h_2} Q_\phi(h_2|v) \cdot v_1 w_{12} h_2 \sum_{h \setminus h_2} \prod_{\hat{j}=1 \setminus 2}^P Q_\phi(h_{\hat{j}}|v) \end{aligned} \quad (36)$$

这里将 $\sum_{h \setminus h_2} \prod_{\hat{j}=1 \setminus 2}^P Q_\phi(h_{\hat{j}}|v)$ 提出了分析一下,

$$\sum_{h \setminus h_2} \prod_{\hat{j}=1 \setminus 2}^P Q_\phi(h_{\hat{j}}|v) = \sum_{h_1} Q_\phi(h_1|v) \sum_{h_3} Q_\phi(h_3|v) \sum_{h_4} Q_\phi(h_4|v) \cdots \quad (37)$$

显然, $\sum_{h_1} Q_\phi(h_1|v) = \sum_{h_3} Q_\phi(h_3|v) = \sum_{h_4} Q_\phi(h_4|v) = \cdots = 1$ 。所以, $\sum_{h \setminus h_2} \prod_{\hat{j}=1 \setminus 2}^P Q_\phi(h_{\hat{j}}|v) = 1$ 。那么,

$$\begin{aligned} \sum_{h_2} Q_\phi(h_2|v) \cdot v_1 w_{12} h_2 \sum_{h \setminus h_2} \prod_{\hat{j}=1 \setminus 2}^P Q_\phi(h_{\hat{j}}|v) &= \sum_{h_2} Q_\phi(h_2|v) \cdot v_1 w_{12} h_2 \\ &= Q_\phi(h_2 = 1|v) \cdot v_1 w_{12} \times 1 + Q_\phi(h_2 = 0|v) \cdot v_1 w_{12} \times 0 \\ &= Q_\phi(h_2 = 1|v) \cdot v_1 w_{12} = \phi_2 v_1 w_{12} \end{aligned} \quad (38)$$

那么, 依次类推, 可以得出:

$$\textcircled{1} = \sum_{i=1}^D \sum_j^P \phi_j v_i w_{ij} \quad (39)$$

而 ② 的做法相对复杂一些，基本思想和 ① 的分解，基本一致，也是要想办法将 h_j 分解出来。那么，目标为将其中和 h_j 相关的项分解出来：

$$\sum_{\hat{j}=1}^P \sum_{m=1 \setminus j}^P h_{\hat{j}} J_{\hat{j}m} h_m \quad (40)$$

大体求解思路是可以分成如下四个部分：

$$\begin{cases} \hat{j} \neq j, m \neq j \\ \hat{j} = j, m = j \\ \hat{j} = j, m \neq j \\ \hat{j} \neq j, m = j \end{cases} \quad (41)$$

其中， $\hat{j} = j, m = j$ 的情况下 $J_{jj} = 0$ ，直接省略掉。 $\hat{j} = j, m \neq j$ 和 $\hat{j} \neq j, m = j$ 是对称的，相加起来可以抵掉 $\frac{1}{2}$ 这个系数，而 $\hat{j} \neq j, m \neq j$ 的情况与 h_j 无关。所以：

$$\textcircled{2} = \sum_{j=1}^P \sum_{m=1 \setminus j}^P \phi_j \phi_m J_{jm} \quad (42)$$

最后一项 ③ 的化简为：

$$\begin{aligned} \textcircled{3} &= \sum_{j=1}^P \left[\phi_j \log \frac{1}{\phi_j} + (1 - \phi_j) \log \frac{1}{(1 - \phi_j)} \right] \\ &= - \sum_{j=1}^P [\phi_j \log \phi_j + (1 - \phi_j) \log (1 - \phi_j)] \end{aligned} \quad (43)$$

我们想得到使 ELBO 最大时对应的 ϕ_j ，那么就对 ϕ_j 求偏导，可以得到：

$$\begin{cases} \frac{\partial \textcircled{1}}{\partial \phi_j} = \sum_{i=1}^D v_i w_{ij} \\ \frac{\partial \textcircled{2}}{\partial \phi_j} = \sum_{m=1 \setminus j}^P \phi_m J_{jm} \\ \frac{\partial \textcircled{3}}{\partial \phi_j} = -\log \frac{\phi_j}{1 - \phi_j} \end{cases} \quad (44)$$

合并起来即为：

$$\frac{\partial [\textcircled{1} + \textcircled{2} + \textcircled{3}]}{\partial \phi_j} = 0$$

解得：

$$\phi_j = \sigma \left(\sum_{i=1}^D v_i w_{ij} + \sum_{m=1 \setminus j}^P \phi_m J_{jm} \right) \quad (45)$$

观察一下 ϕ_j 的结果，里面有一个项为 $\sum_{m=1 \setminus j}^P \phi_m$ 。所以，利用公式 (45) 求解最终结果的方法依然比较坎坷。

首先, $\{\phi_j\}_{j=1}^P$ 都赋予一个初始值。然后依次计算 $\phi_1, \phi_2, \dots, \phi_P$, 得到的结果为第一次迭代 $\{\phi^{(1)}\}$ 。不断的重复这个过程, 直到最后收敛为止, 收敛时得到的结果 $\{\hat{\phi}_j\}_{j=1}^P$ 就是最终的答案。实际上就是求解不动点方程——公式 (45), 采用的是坐标上升法求解。利用不动点方程的求解结果, 可以得到 Q_ϕ :

$$\{\hat{\phi}_j\}_{j=1}^P \implies Q_\phi \quad (46)$$

而 $Q_\phi(h|v) \approx P_{\text{model}}(h|v)$ 。那么, 公式 (12) 中 P_{data} 的计算基本解决了。那么, 就不需要再进行采样了。而对于 P_{model} 还是用 MCMC, 实际上 $P_{\text{model}}(h|v)$, 采样 $P_{\text{model}}(h, v)$ 难度就小了很多了。理论上, 我们给出了一个实际可行的方法。但是, 每一步正向用 VI, 负向用 Gibbs, 计算复杂度还是较大的。而有很多改进的方法, 比如之前讲的用基于对比散度的 Gibbs 采样, 还有后来的概率对比散度, Deep Boltzmann Machines 等。

5 总结

理一下这章的逻辑思路。首先, 我们描述了什么是玻尔兹曼机 (Boltzmann Machines), 描述了其模型表示。下一个问题, 就是如何利用观测数据集来求解参数, 我们介绍了基于极大似然的梯度上升, 经过推导得出了似然梯度的方向。但是, 似然梯度中涉及到对 P_{model} 和 P_{data} 的采样。那么难点就转移到了, 如何从 P_{model} 和 P_{data} 中进行采样。通过分析, 得到玻尔兹曼机求解主要的难点就是 $P_{\text{model}}(h|v)$ 很难求解。

我们和受限玻尔兹曼机的采样进行了对比, 受限玻尔兹曼机中的后验 $P_{\text{model}}(h|v)$ 可以直接计算, 而玻尔兹曼机中不行。所以, 为了求解后验分布, 介绍了 MCMC 中的 Gibbs 采样的思想。Gibbs 采样是一维一维的采样, 那么需要满足单个节点的条件概率分布可以求出。幸运的是, Boltzmann Machines 中可以求出。下一步则进行了单个节点条件概率的详细推导。

MCMC 虽然提供了一个理论上的可行方法。可惜, 无法解决大规模求解的问题。所以, 介绍了 Hinton 提出的变分推断 (Variational Inference), 用一个简单分布 Q_ϕ 来近似 $P_{\text{model}}(h|v)$ 。通过推导, 我们得到了 ϕ 的不动点方程, 使用坐标上升法即可得到 ϕ 的参数表达式。从而成功的求解 $P_{\text{model}}(h|v)$ 。